



Predicción de precios de las viviendas de Boston mediante Regresión Lineal

Computación II

Profesor: Javier Leiva

Estudiantes: Matías González y Antonia Ruz

Índice

Introducción.....	3
Análisis Exploratorio	4
Limpieza de datos	4
Correlación entre variables	6
Modelo de Regresión Lineal	8
Modelo inicial (13 variables)	9
Modelo con variables seleccionadas	11
Resultados.....	14
Conclusiones	16

Introducción

En este informe se detalla el análisis realizado al conjunto de datos “Boston Housing”, publicado originalmente por Harrison y Rubinfeld (1978) a partir de datos del Servicio de Censo de los Estados Unidos. Actualmente se encuentra disponible en el repositorio StatLib (<http://lib.stat.cmu.edu/datasets/boston>). El dataset consiste en 506 observaciones y 14 variables asociadas a características de viviendas en un sector de Boston, Massachusetts. A partir de esta muestra, se busca predecir el valor mediano de las casas ocupadas (medido en miles de dólares) mediante un modelo de regresión lineal múltiple, utilizando Python como lenguaje de programación. A continuación, se listan las variables en estudio y sus descripciones.

Variables:

1. **CRIM** – Tasa de criminalidad per cápita por ciudad.
2. **ZN** – Proporción de terreno residencial dividido en lotes de más de 25,000 pies².
3. **INDUS** – Proporción de acres destinados a negocios no minoristas por ciudad.
4. **CHAS** – Variable ficticia (= 1 si la zona colinda con el río Charles, 0 en caso contrario).
5. **NOX** – Concentración de óxidos de nitrógeno (partes por 10 millones).
6. **RM** – Número promedio de habitaciones por vivienda.
7. **AGE** – Proporción de viviendas ocupadas por sus dueños construidas antes de 1940.
8. **DIS** – Distancia ponderada a cinco centros de empleo en Boston.
9. **RAD** – Índice de accesibilidad a carreteras radiales.
10. **TAX** – Tasa de impuesto a la propiedad por cada \$10,000.
11. **PTRATIO** – Ratio alumno–profesor por ciudad.
12. **B** – $1000(Bk - 0.63)^2$, donde Bk es la proporción de habitantes negros por ciudad.
13. **LSTAT** – % de población con bajo estatus socioeconómico.
14. **MEDV** – Valor medio de las viviendas ocupadas por sus dueños (en miles de dólares).

Análisis Exploratorio

Limpieza de datos

Partiremos por importar una serie de librerías y cargar el dataset, para inspeccionar los tipos de variables y posibles datos nulos. Primeramente cargando 5 filas para observar la forma de nuestra base.

Tabla 1. *Primeras 5 filas del data frame (función head) del conjunto de datos Boston Housing*

	crim	zn	indus	chas	nox	rm	age	dis	rad	tax	ptratio	b	lstat	medv
0	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.0900	1	296	15.3	396.90	4.98	24.0
1	0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242	17.8	396.90	9.14	21.6
2	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222	18.7	396.90	5.33	36.2

Fuente: Boston Housing Dataset, Harrison, D. & Rubinfeld, D. L. (1978)

Se descarta existencia de datos nulos y todas las variables han sido ingresadas como numéricas. Siendo tres números enteros (int64) y el resto números racionales (fracciones o float). Se contabilizan 506 datos.

```
Data columns (total 14 columns):
#   Column      Non-Null Count  Dtype
---  -
0   crim        506 non-null    float64
1   zn          506 non-null    float64
2   indus       506 non-null    float64
3   chas        506 non-null    int64
4   nox         506 non-null    float64
5   rm          506 non-null    float64
6   age         506 non-null    float64
7   dis         506 non-null    float64
8   rad         506 non-null    int64
9   tax         506 non-null    int64
10  ptratio     506 non-null    float64
11  b           506 non-null    float64
12  lstat       506 non-null    float64
13  medv        506 non-null    float64
dtypes: float64(11), int64(3)
memory usage: 55.5 KB
```

Tabla 2. *Tipo de variables y conteo de datos válidos (función info)*

Se obtienen las medidas descriptivas para tener una idea de la base de datos. Existen al menos 3 variables con alto promedio de desvíos sobre la media (zn, age, y b). Nótese que la variable chas es realmente una categórica de opciones binarias que referencia colindancia con el río Charles

	crim	zn	indus	chas	nox	rm	lstat
count	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000
mean	3.613524	11.363636	11.136779	0.069170	0.554695	6.284634	12.653063
std	8.601545	23.322453	6.860353	0.253994	0.115878	0.702617	7.141062
min	0.006320	0.000000	0.460000	0.000000	0.385000	3.561000	1.730000
25%	0.082045	0.000000	5.190000	0.000000	0.449000	5.885500	6.950000
50%	0.256510	0.000000	9.690000	0.000000	0.538000	6.208500	11.360000
75%	3.677083	12.500000	18.100000	0.000000	0.624000	6.623500	16.955000
max	88.976200	100.000000	27.740000	1.000000	0.871000	8.780000	37.970000

	age	dis	rad	tax	ptratio	b	medv
count	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000	506.000000
mean	68.574901	3.795043	9.549407	408.237154	18.455534	356.674032	22.532806
std	28.148861	2.105710	8.707259	168.537116	2.164946	91.294864	9.197104
min	2.900000	1.129600	1.000000	187.000000	12.600000	0.320000	5.000000
25%	45.025000	2.100175	4.000000	279.000000	17.400000	375.377500	17.025000
50%	77.500000	3.207450	5.000000	330.000000	19.050000	391.440000	21.200000
75%	94.075000	5.188425	24.000000	666.000000	20.200000	396.225000	25.000000
max	100.000000	12.126500	24.000000	711.000000	22.000000	396.900000	50.000000

Tabla 3. Medidas descriptivas de las variables (función describe)

No hay necesidad de limpiar la base de datos. Sin embargo, para una mejor interpretación, vamos a renombrar once de las variables.

1. **CRIM** – crim_rate
2. **ZN** – land_rate
3. **INDUS** – comercial_acre_rate
4. **CHAS** – river
5. **NOX** – nitro_ox
6. **RM** – room_per_house
7. **DIS** – job_dist
8. **RAD** – road_index
9. **TAX** – tax_rate
10. **PTRATIO** – student_teacher_ratio
11. **LSTAT** – low_inc_perc

Correlación entre variables

Con los datos limpios y fáciles de consultar, se construye una matriz de correlación para examinar el porcentaje de correlación que tienen todas las variables entre sí. De lo que se obtiene por normal general, una alta relación entre las variables.




Gráfico 1. Mapa de calor. Matriz de correlación.

Se puede ver en este mapa que las correlaciones más marcadas son entre casas antiguas y la accesibilidad a carreteras. Le siguen la relación entre la tasa de impuesto y el espacio que abarcan grandes negocios y de la relación que tiene la mediana de los precios con el número de habitaciones. Como nos interesa predecir los precios de las viviendas, vamos a examinar la relación entre las distintas variables predictoras con la variable “target” a través de pairplots con los que buscar posibles relaciones lineales que sirvan para construir el modelo de regresión lineal.




Gráfico 2. Pairplot. Correlación entre variables predictoras y target.

Del pairplot se obtiene que variables como las casas antiguas, la colindancia con el río Charles, y la concentración de óxidos de nitrógeno tiene una leve o nula relación con la variable. Con interesantes candidatos entre el número de habitaciones, los terrenos residenciales, los grandes negocios, la tasa de impuestos y la tasa de crímenes. Con estas últimas tres correlaciones siendo negativas. Hay una interesante relación muy potente con el porcentaje de hogares de bajos recursos, pero que no parece ser lineal. Para determinar de forma más precisa las variables, se utilizarán métodos estadísticos como la regresión lineal para “selección forward”.

Modelo de Regresión Lineal

La regresión lineal es un modelo de regresión en el cual se incluyen una o más variables independientes que funcionan como predictoras de una variable dependiente denominada *y*. Un modelo de regresión lineal busca encontrar una ecuación que relacione las variables independientes con la variable dependiente mediante coeficientes para cada variable independiente (Beta de X). Los conceptos claves de esta misma son:

Los **coeficientes de las variables predictoras (independientes)** para predecir valores de la variable dependiente. Los **valores predichos**, que corresponden al valor que “ajusta” el modelo a partir de los valores de x en un punto concreto. Los **residuos**, que son el resto de la diferencia entre los valores predichos y los reales. El **R^2 o “score”** del modelo que representa la variabilidad de la variable dependiente que es capaz de explicar el modelo.

Los modelos de regresión lineal se basan en 3 supuestos cuando solo hay una variable predictora, y 5 cuando hay más de una variable predictora. Estos se han de verificar para validar el modelo.

- (1) Independencia: los residuos deben ser independientes entre sí.
- (2) Homocedasticidad: debe haber homogeneidad en las varianzas de los residuos, es decir, la variabilidad de los residuos debe ser constante.
- (3) Normalidad: los residuos deben estar distribuidos normalmente con una media de cero.

En caso de haber más de una variable predictora, se deben validar otros dos supuestos.

- (4) Linealidad: se supone que la relación entre la variable respuesta y las variables explicativas es lineal.
- (5) No multicolinealidad: las variables explicativas incluidas en el modelo no pueden estar relacionadas entre sí o, al menos, su relación debe ser muy débil.

Con el concepto de regresión lineal general establecido, aplicaremos esta modelización a nuestra base de datos para predecir la mediana de los precios de las viviendas.

Se separan los datos en tres subconjuntos.

- (1) De entrenamiento (303 observaciones, 60% de los datos): datos con los que entrenar un modelo de regresión lineal y verificar los supuestos de este mismo para posteriormente aplicar el modelo al subconjunto de prueba.
- (2) De selección de variables (101 observaciones, 20% de los datos): a través regresión lineal se hace una forward selection por la que encontrar las variables con las que ajustar el modelo final.
- (3) De prueba (102 observaciones, 20% de los datos): se aplica el modelo ajustado a este subconjunto para comprobar su eficacia y capacidad de predecir de forma precisa los valores de la variable target (mediana de precio de las viviendas).

Modelo inicial (13 variables)

Como primer intento de ajustar un modelo de regresión lineal, se construye uno utilizando todas las variables predictoras de las que dispone el dataframe, entrenado con el subconjunto de entrenamiento. Se obtiene un R^2 , lo que indica que el modelo es capaz de explicar un 73,9% de la variabilidad de los precios de la vivienda. Una tabla con los resultados del modelo.

OLS Regression Results						
=====						
Dep. Variable:	MEDV	R-squared:	0.739			
Model:	OLS	Adj. R-squared:	0.728			
Method:	Least Squares	F-statistic:	68.45			
Date:	Thu, 30 Oct 2025	Prob (F-statistic):	3.31e-77			
Time:	05:17:51	Log-Likelihood:	-898.30			
No. Observations:	303	AIC:	1823.			
Df Residuals:	290	BIC:	1871.			
Df Model:	12					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

Intercept	32.3235	6.322	5.113	0.000	19.881	44.766
crime_rate	-0.1044	0.036	-2.924	0.004	-0.175	-0.034
land_rate	0.0568	0.018	3.146	0.002	0.021	0.092
comercial_acre_rate	0.0238	0.078	0.304	0.761	-0.130	0.178
river	2.9093	1.097	2.653	0.008	0.751	5.068
nitro_ox	-15.6012	5.105	-3.056	0.002	-25.648	-5.554
room_per_house	4.3865	0.570	7.701	0.000	3.265	5.508
age	-0.0121	0.017	-0.694	0.488	-0.046	0.022
job_dist	-1.3420	0.250	-5.366	0.000	-1.834	-0.850
road_index	0.2365	0.086	2.761	0.006	0.068	0.405
tax_rate	-0.0142	0.005	-3.006	0.003	-0.024	-0.005
teacher_student_ratio	-0.7933	0.169	-4.687	0.000	-1.126	-0.460
low_inc_perc	-0.4329	0.068	-6.408	0.000	-0.566	-0.300

Tabla 4. Resultados modelo de regresión lineal inicial

Verificación de supuestos:

(Independencia) Test de Durbin-Watson: 1.882

El test de Durbin Watson resulta en un 1.8, lo que no se aleja demasiado de dos, por lo que se puede afirmar que los residuos son independientes entre sí.

(Homocedastidad) Valor P de Breusch-Pagan: 0.00011707840320396679

Como la hipótesis nula es que los son homocédásticos, y el valor p es muy menor a 0.05, se debe rechazar la hipótesis nula. Por lo tanto, los residuos no son homocedásticos ya que los estos tienen una distinta varianza.

(Normalidad) Valor P de Kolmogorov-Smirnov: 0.0009999999999998899

Como la hipótesis nula es que los residuos tienen una distribución normal, y el valor p es muy menor a 0.05, se debe rechazar la hipótesis nula. Por lo tanto, los residuos no tienen una distribución normal ya que estos no tienen una media de cero.

(No multicolinealidad) Tabla de Valores de Inflación:

	Variable	VIF
0	const	558.817593
1	crime_rate	1.730270
2	land_rate	2.358419
3	comercial_acre_rate	4.015049
4	river	1.070259
5	nitro_ox	4.554889
6	room_per_house	2.067605
7	age	3.295477
8	job_dist	3.887650
9	road_index	7.437061
10	tax_rate	8.501874
11	teacher_student_ratio	1.826889
12	B	1.335911
13	low_inc_perc	3.279144

Tabla 5. Multicolinealidad de las variables del modelo inicial

La tasa de impuestos y el acceso a carreteras presentan una correlación muy elevada con el resto de variables. Esto podría distorsionar la eficacia del modelo.

Debido a la alta correlación entre las variables predictoras, este modelo puede estar sobrevalorando algunas variables e infravalorando otras. Además de que este modelo no está cumpliendo los supuestos de homocedasticidad, normalidad y no multicolinealidad. Por lo que vamos a probar a reducir la cantidad de variables predictoras, combinando algunas obtenidas por forward selection de una regresión lineal aplicada sobre el subconjunto de validación, con otras que se tantearon debido a su alta correlación con la variable predictora. Esto aseguró un mejor cumplimiento de los supuestos de la regresión lineal.

Modelo con variables seleccionadas

Con este segundo modelo se acotaron las variables predictoras a cinco. Siendo estas

- **low_inc_perc**
- **room_per_house**
- **crime_rate**
- **comercial_acre_rate**
- **land_rate**

Con lo que similar al modelo anterior, podemos examinar los resultados de este modelo y verificar si cumple con los supuestos de la regresión lineal. Se entrenó con el subconjunto de entrenamiento, al igual que el modelo inicial.

Obteniendo un R^2 de 0.661, indicando que el modelo explica un 66,1% de la variabilidad de la mediana de precio de las casas.

Dep. Variable:	MEDV	R-squared:	0.661			
Model:	OLS	Adj. R-squared:	0.655			
Method:	Least Squares	F-statistic:	115.8			
Date:	Thu, 30 Oct 2025	Prob (F-statistic):	1.29e-67			
Time:	05:57:59	Log-Likelihood:	-937.96			
No. Observations:	303	AIC:	1888.			
Df Residuals:	297	BIC:	1910.			
Df Model:	5					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

Intercept	-4.4252	4.192	-1.056	0.292	-12.675	3.825
low_inc_perc	-0.4510	0.067	-6.699	0.000	-0.584	-0.319
room_per_house	5.3837	0.580	9.289	0.000	4.243	6.524
crime_rate	-0.1117	0.035	-3.196	0.002	-0.181	-0.043
comercial_acre_rate	-0.0986	0.061	-1.604	0.110	-0.220	0.022
land_rate	0.0224	0.016	1.412	0.159	-0.009	0.054

Tabla 6. Resultados modelo de regresión lineal de variables seleccionadas

(Independencia) Test de Durbin-Watson: 1.8817884604371713

El test de Durbin Watson resulta en un 1.8, al igual que el modelo anterior, lo que no se aleja demasiado de dos, por lo que se puede afirmar que los residuos son independientes entre sí.

(Homocedastidad) Valor P de Breusch-Pagan: 0.06578165976468124

Debido a que la hipótesis nula es que los son homocédasticos, y el valor p es mayor a 0.05, la hipótesis nula no se rechaza y es posible afirmar que los residuos son homocédasticos y para todo valor de cada variable predictora, la varianza es la misma.




Gráfico 3. Scatterplot de los valores predichos y los residuos.

(Normalidad) Valor P de Kolmogorov-Smirnov: 0.0009999999999998899

Como la hipótesis nula es que los residuos tienen una distribución normal, y el valor p es muy menor a 0.05, se debe rechazar la hipótesis nula. Por lo tanto, los residuos no tienen una distribución normal ya que estos no tienen una media de cero. Si graficamos vemos una clara asimetría afectada por valores atípicos muy altos.




Gráfico 4. Histograma de los residuos en intervalos

(No multicolinealidad) Tabla de Valores de Inflación:

	Variable	VIF
0	low_inc_perc	6.481190
1	room_per_house	6.054495
2	crime_rate	1.480754
3	comercial_acre_rate	6.618005
4	land_rate	1.774427

Tabla 7. Multicolinealidad de las variables del modelo de variables seleccionadas

Tanto la tasa de crimen como la proporción de terreno residencial presentan una casi nula correlación con otras variables predictoras. Mientras que las otras tres variables presentan una correlación moderada que vamos a aceptar.

Habiendo decidido un modelo con el que quedarnos, vamos a comentar los resultados de este mismo cuando se aplica nuestra regresión al subconjunto de prueba.

Resultados

Coefficientes

Intercept	-4.4252
low_inc_perc	-0.4510
room_per_house	5.3837
crime_rate	-0.1117
comercial_acre_rate	-0.0986
land_rate	0.0224

Tabla 8. Coeficientes del modelo de variables seleccionadas.

Con el aumento en una unidad del porcentaje de hogares con bajos recursos en el barrio, el valor de la mediana de las viviendas disminuye en un 0.45. Si aumenta en uno la cantidad de habitaciones de las viviendas, la mediana de los precios aumenta en cinco unidades. A mayor sea la tasa de crimen, menor será la mediana de los precios. Disminuyendo los precios por una unidad (que recordemos que es medida en miles de dólares) por cada diez unidades que aumenta la tasa del crimen.




Gráfico 5. Scatterplot los valores predichos con los valores reales.

Métricas en el subconjunto de prueba:

Coefficiente de Determinación (R^2): 0.6777

El R^2 representa, en porcentaje, lo que es capaz de explicar el modelo de la variabilidad en la variable dependiente (en este caso, la mediana de los precios de las viviendas). Un 67.7% es un indicador de rendimiento predictivo moderado

Error Cuadrático Medio (MSE): 22.8721

Este valor está expresado al cuadrado y se usa principalmente como paso intermedio para calcular el (RMSE), este valor se suele usar para penalizar las predicciones alejadas de la realidad

Raíz del Error Cuadrático Medio (RMSE): 4.7825

Este valor representa la desviación estándar de los errores de predicción dándonos una idea de la desviación típica de una predicción.

Error Absoluto Medio (MAE): 3.4916

Este valor nos dice que, en promedio, las predicciones del modelo tienen un error de 3.49 unidades por encima o por debajo del valor real porque está expresado en valor absoluto. Nótese que el RMSE (4.7825) es notablemente más alto que el MAE (3.4916). Esto sugiere que, si bien el error promedio es de 3.49, el modelo tiende a cometer algunos errores

Conclusiones

Durante el proceso de análisis (que no llegó a los resultados finales y fue borrado del código debido a la cantidad de iteraciones), nos encontramos casi en todo momento con unos residuos heterocedásticos con una distribución asimétrica, incumpliendo dos supuestos de la regresión lineal. En algunos casos incluso con una forward selection se incumplía la no multicolinealidad. Por lo que fue un constante remover y añadir constantes para ver los cambios de comportamiento del modelo. Un proceso fascinante, pero para el que nos topamos con una pared ante la falta de herramientas matemáticas y técnicas para enfrentar y comprender reescalados y transformaciones de las variables para obtener un modelo más preciso. En documentaciones externas, aparecían distintas formas de reajustar los datos para lograr un modelo más preciso. Como el Z-Score planteado por **Akash** Agnihotri en un blog de [Kaggle](#), el cual pese a comprender matemáticamente, nos vimos incapaces de implementar en nuestro código y análisis final o la normalización de la variable target mediante [transformación logarítmica](#) propuesta por chatgpt.

El proceso fue tanto un ejercicio de humildad como una shot de motivación para entender la potencia de las herramientas tanto matemáticas como estadísticas en la predicción de valores (o sucesos) a partir de toneladas de datos que se convierten en información, y pulen en conocimiento.

Bibliografía consultadaⁱ

ⁱ Dataset original:

Harrison, D. and Rubinfeld, D.L. `Hedonic prices and the demand for clean air', J. Environ. Economics & Management, vol.5, 81-102, 1978.

Agnihotri. (2019). *Linear Regression and PCA - Boston Housing*.

Kaggle. <https://www.kaggle.com/code/agnihotri/linear-regression-and-pca-boston-housing>

Juárez, M. G. (2025). *Regresión lineal múltiple*. Probabilidad y

Estadística. <https://www.probabilidadyestadistica.net/regresion-lineal-multiple>